

Project Big Data & Predictive Analytics Lanjut

**Analisis Pola Transaksi dan Segmentasi Pelanggan Coffee Shop
Menggunakan PySpark & MLlib**



Disusun Oleh:

Alfrendra Rizky Pratama 23.11.5830

Virido Maulana Firdaus 23.11.5829

Program Studi S1 Informatika

Fakultas Ilmu Komputer

Universitas Amikom Yogyakarta

2025

MODUL 1: Studi Kasus & Tinjauan Dataset

1.1 Latar Belakang Masalah

Dalam industri ritel F&B (Food & Beverage), memahami pola perilaku pelanggan adalah kunci efisiensi operasional. Coffee Shop dalam studi kasus ini menghadapi tantangan dalam menentukan stok harian dan strategi promosi yang tepat karena belum adanya segmentasi pelanggan yang jelas. Project ini bertujuan mengubah data transaksi mentah menjadi *business intelligence* yang dapat ditindaklanjuti.

1.2 Analisis Karakteristik Big Data (5V)

Dataset yang digunakan adalah data transaksi penjualan kopi (Januari - Juni 2023) yang memenuhi karakteristik Big Data sebagai berikut:

- Volume: Terdiri dari ±149.000 baris data transaksi. Meskipun secara fisik kecil, volume ini cukup untuk mensimulasikan beban kerja pemrosesan terdistribusi.
- Variety: Data bersifat relasional/terstruktur yang mencakup dimensi Waktu (*Transaction Date/Time*), Lokasi (*Store ID*), Produk (*Category, Type*), dan Metrik (*Qty, Price*).
- Velocity: Data bersifat *batch historical*, namun pipeline dirancang untuk siap menerima data *streaming* harian.
- Veracity: Data memiliki tantangan kualitas nyata, seperti inkonsistensi format tanggal (campuran format ISO dan format regional) serta variasi delimiter CSV.
- Value: Hasil akhir berupa segmentasi pelanggan berguna untuk strategi *upselling* dan manajemen inventori.

MODUL 2: Strategi Penyimpanan Data (Storage Layer)

2.1 Arsitektur Data Lake (Simulasi HDFS)

Kami menerapkan konsep *Data Lake* sederhana dengan memisahkan penyimpanan menjadi dua *layer* untuk menjaga integritas data:

1. Raw Layer (*/raw*): Tempat penyimpanan data mentah asli (*.csv*) yang di-*ingest* tanpa modifikasi. Ini menjamin *single source of truth*.
2. Processed Layer (*/processed*): Tempat penyimpanan data bersih dalam format Parquet.

2.2 Pemilihan Format Parquet

Kami mentransformasi data dari CSV ke Parquet di tahap akhir *engineering* dengan alasan:

- Columnar Storage: Mempercepat query analitik (seperti agregasi kolom *revenue*) dibanding pembacaan baris per baris pada CSV.
- Schema Preservation: Parquet menyimpan metadata tipe data (Integer, Date, Double), sehingga tidak perlu melakukan *casting* ulang saat data dibaca kembali.

MODUL 3: Preprocessing & Data Quality Control

3.1 Tantangan Teknis (Data Inconsistency)

Pada tahap ini, ditemukan dua masalah kritis yang umum terjadi di dunia nyata:

1. Delimiter Mismatch: File CSV menggunakan pemisah titik koma (;) bukan koma standar, menyebabkan data terbaca sebagai satu kolom panjang.
2. Date Format Ambiguity: Terdapat percampuran format tanggal standar (yyyy-MM-dd) dan format regional (dd/MM/yyyy).
3. Decimal Formatting: Format mata uang menggunakan koma (,) sebagai desimal (gaya Eropa), yang tidak dikenali oleh Spark secara default.

3.2 Solusi & Implementasi (Robust Parsing)

Kami menerapkan pendekatan *Robust Data Engineering*:

- Automated Delimiter Detection: Script dirancang untuk mendeteksi anomali kolom dan melakukan *reload* otomatis dengan separator yang benar.
- Legacy Time Parser Policy: Kami mengonfigurasi Spark Session dengan `.config("spark.sql.legacy.timeParserPolicy", "LEGACY")` agar Spark tidak *crash* saat menemukan format tanggal non-standar.
- Coalesce Strategy: Menggunakan fungsi `coalesce()` untuk mencoba berbagai pola format tanggal secara berurutan hingga ditemukan format yang valid.
- Regex Replacement: Membersihkan format harga dengan `regexp_replace` sebelum *type casting*.

3.3 Data Quality Check

Setelah pembersihan, dilakukan pengecekan *null values* dan *business logic anomalies* (misal: harga negatif). Hasil akhir menunjukkan 0 *missing values* pada kolom kritis, menjamin data siap untuk analisis.

MODUL 4: Exploratory Data Analysis (EDA)

4.1 Analisis Performa Toko

Berdasarkan agregasi *Revenue*, toko di lokasi "*Hell's Kitchen*" dan "*Lower Manhattan*" menunjukkan performa tertinggi. Ini mengindikasikan bahwa area dengan densitas pekerja/turis tinggi memiliki volume transaksi terbesar.

4.2 Analisis Waktu (Peak Hours)

Visualisasi tren per jam menunjukkan pola "**Morning Rush**" yang signifikan antara pukul 07.00 - 10.00 pagi. Insight ini menyarankan manajemen untuk menempatkan jumlah staf (barista) maksimal pada jam tersebut dan melakukan *restocking* bahan baku sebelum jam 07.00 pagi.

4.3 Analisis Produk

Produk kategori *Coffee* dan *Tea* mendominasi penjualan secara kuantitas (*transaction_qty*). Hal ini mengonfirmasi bahwa produk inti (*core product*) masih menjadi pendorong utama pendapatan dibandingkan produk pelengkap seperti *Bakery*.

MODUL 5: Batch Processing dengan RDD (MapReduce)

5.1 Implementasi Low-Level API

Meskipun Spark SQL lebih modern, kami mendemonstrasikan pemahaman terhadap konsep dasar komputasi terdistribusi menggunakan RDD (*Resilient Distributed Dataset*).

5.2 Logika MapReduce

Studi kasus yang digunakan adalah perhitungan Total Revenue per Kategori Produk:

- Map Phase: Transformasi setiap baris data menjadi pasangan *key-value* -> (Product_Category, Revenue).
- Reduce Phase: Menggunakan `reduceByKey` dengan fungsi lambda $\lambda x, y: x + y$ untuk mengakumulasi nilai *Revenue* berdasarkan *Key* yang sama secara paralel di seluruh *partition*.

Hasil yang didapatkan konsisten dengan perhitungan Spark SQL, membuktikan validitas logika *distributed computing* yang diterapkan.

MODUL 6: Spark SQL & Feature Engineering

6.1 Transformasi Data untuk Machine Learning

Data transaksi mentah (level produk) tidak dapat langsung digunakan untuk segmentasi pelanggan. Oleh karena itu, kami melakukan Agregasi Level Keranjang (Basket Level Aggregation).

6.2 Pembentukan Fitur (Feature Extraction)

Kami mengasumsikan satu transaksi unik (*Basket*) terjadi pada kombinasi **Store**, **Date**, dan **Time** yang sama. Fitur yang diekstrak meliputi:

- Basket Size (Qty): Jumlah item yang dibeli dalam satu struk.
- Basket Amount (Monetary): Total uang yang dikeluarkan dalam satu struk.
- Shopping Hour: Jam terjadinya transaksi (untuk melihat kebiasaan waktu).

Proses ini mengubah data dari dimensi *Product-Centric* menjadi *Customer-Behavior-Centric*.

MODUL 7: Machine Learning Modeling (Clustering)

7.1 Pemilihan Algoritma

Kami menggunakan *K-Means Clustering* (Unsupervised Learning) karena data tidak memiliki label target (tidak ada kolom "Tipe Pelanggan"). Tujuan model adalah membiarkan algoritma menemukan pola pengelompokan alami berdasarkan kemiripan fitur.

7.2 Preprocessing ML (Vector Assembly & Scaling)

- Vector Assembler: Menggabungkan fitur numerik menjadi satu vektor kolom.
- Standard Scaler: Melakukan standarisasi data (Mean=0, Std=1). Langkah ini krusial karena fitur *Amount* (puluhan dolar) memiliki rentang nilai yang jauh lebih besar dari *Qty* (satuan), yang dapat membiaskan perhitungan jarak Euclidean pada K-Means jika tidak diskalakan.

MODUL 8: Hyperparameter Tuning

8.1 Penentuan Jumlah Cluster Optimal (K)

Kami melakukan eksperimen dengan nilai $K = 2$ hingga 6. Evaluasi dilakukan menggunakan dua metode:

1. Elbow Method (SSE): Mencari titik di mana penurunan *error* mulai melandai.
2. Silhouette Score: Mengukur seberapa dekat titik data dengan clusternya sendiri dibandingkan dengan cluster tetangga.

8.2 Hasil Tuning

Berdasarkan grafik evaluasi, ditemukan bahwa $K = 3$ memberikan keseimbangan terbaik antara kompleksitas model dan pemisahan cluster yang jelas (Silhouette Score tertinggi).

MODUL 9: Evaluasi & Interpretasi Bisnis

9.1 Profil Cluster (Customer Persona)

Setelah melakukan *inverse scaling* pada titik pusat cluster (*centroids*), kami mengidentifikasi 3 tipe perilaku pelanggan:

1. **Cluster 0 - "The Morning Commuter" (Pekerja Pagi):**
 - *Karakteristik:* Membeli rata-rata 1 item, nilai transaksi rendah, terjadi di pagi hari (jam 7-9).
 - *Produk:* Kemungkinan besar hanya membeli kopi untuk dibawa kerja.
2. **Cluster 1 - "The Leisure Spender" (Pelanggan Santai/Siang):**
 - *Karakteristik:* Membeli 1-2 item dengan nilai transaksi sedang, terjadi di siang/sore hari.
 - *Produk:* Kombinasi minuman dan camilan ringan.
3. **Cluster 2 - "The Bulk Buyer/Group" (Pembelian Kelompok):**
 - *Karakteristik:* Membeli jumlah banyak (>3 item), nilai transaksi tinggi.
 - *Konteks:* Kemungkinan pesanan untuk rapat kantor atau kelompok teman.

9.2 Rekomendasi Bisnis

- Untuk Cluster 0: Fokus pada kecepatan layanan (*speed of service*) di pagi hari.
- Untuk Cluster 2: Buat paket *bundling* ("Buy 4 get 1 Free") untuk mendorong nilai transaksi kelompok lebih tinggi.

KESIMPULAN

Project ini berhasil mendemonstrasikan implementasi pipeline Big Data *end-to-end*, mulai dari penanganan data mentah yang "kotor" menggunakan teknik *robust engineering* di PySpark, hingga ekstraksi *insight* strategis menggunakan Machine Learning.

Penggunaan arsitektur terdistribusi (Spark) terbukti mampu menangani kompleksitas pembersihan data dan komputasi matematis (Clustering) secara efisien. Hasil segmentasi pelanggan memberikan landasan data yang kuat bagi manajemen Coffee Shop untuk mengambil keputusan berbasis fakta, bukan asumsi.